

Analyse des Systèmes Linéaires et Optimisation

1 Systèmes Linéaires et Méthodes de Résolution

1.1 Introduction

Le problème fondamental de l'algèbre linéaire numérique consiste à résoudre un système de la forme :

$$Ax = b$$

Où $A \in \mathbb{C}^{N \times N}$ est une matrice carrée et $b \in \mathbb{C}^N$ est un vecteur donné.

1.2 Méthode de Newton

Pour les cas non-linéaires où l'on cherche x tel que $F(x) = 0$ avec $F : \mathbb{R}^N \rightarrow \mathbb{R}^N$, on utilise la méthode itérative de Newton :

$$x_{n+1} = x_n - F'(x_n)^{-1}F(x_n) \quad (1)$$

1.3 Conditions d'existence et d'unicité

Si $A \in \mathbb{C}^{N \times N}$, les assertions suivantes sont équivalentes pour l'existence et l'unicité d'une solution unique ($\exists! Ax = b, \forall b$) :

- A est bijective.
- A est injective (d'après le théorème du rang).
- A est surjective.
- $\det A \neq 0$.
- 0 n'est pas une valeur propre de A .

1.4 Cas des matrices non-inversibles

Soit A une matrice carrée non-inversible. Dans ce cas, la solution n'est pas unique. Une solution existe si et seulement si b appartient à l'image de A :

$$\exists \text{ sol} \iff b \in \text{Im } A = \text{Vect}(A_1, \dots, A_n)$$

où $A_1, \dots, A_n$ sont les colonnes de la matrice A .

Example 1.1. Considérons le système suivant :

$$\begin{aligned} 2x + 4y &= \alpha \\ 4x + 8y &= \beta \end{aligned}$$

L'image de A est donnée par :

$$\text{Im } A = \left\{ \begin{pmatrix} \alpha \\ \beta \end{pmatrix} \text{ tq } 2\alpha = \beta \right\}$$

Ceci correspond à la condition $2\alpha - \beta = 0$, soit l'orthogonalité au vecteur $\begin{pmatrix} 2 \\ -1 \end{pmatrix}$.

1.5 Propriété Fondamentale des Espaces

Proposition 1.2. Si $A \in \mathbb{C}^{N \times M}$, nous avons les décompositions en somme directe suivantes :

$$\mathbb{C}^N = \text{Im } A \oplus \ker(A^*)$$

$$\mathbb{C}^M = \text{Im } A^* \oplus \ker(A)$$

Preuve. Montrons que $\ker A = (\text{Im } A^*)^\perp$.

1. Soit $x \in \ker A$. Alors $Ax = 0$. Soit $y \in \text{Im } A^*$, il existe z tel que $y = A^*z$. Calculons le produit scalaire :

$$\langle x, y \rangle = \langle x, A^*z \rangle = \langle Ax, z \rangle = \langle 0, z \rangle = 0$$

Donc $x \in (\text{Im } A^*)^\perp$, d'où $\ker A \subset (\text{Im } A^*)^\perp$.

2. Inversement, soit $x \in (\text{Im } A^*)^\perp$. Par définition, pour tout $y \in \text{Im } A^*$, $\langle x, y \rangle = 0$. Ainsi, $\forall z, \langle x, A^*z \rangle = 0$. Par propriété de l'adjoint, $\forall z, \langle Ax, z \rangle = 0$. Ceci implique que $Ax = 0$, donc $x \in \ker A$.

Nous en déduisons que $\ker A = (\text{Im } A^*)^\perp$. □

2 Méthodes de Décomposition Directe

2.1 Pivot de Gauss

L'algorithme du pivot de Gauss permet de transformer le système en un système triangulaire.

Exemple 2.1. Considérons le système :

$$x + 2y + 3z = 1$$

$$4x + 5y + 6z = 2$$

$$7x + 8y + 10z = 3$$

On effectue les opérations sur les lignes :

$$L_2 \leftarrow L_2 - 4L_1$$

$$L_3 \leftarrow L_3 - 7L_1$$

Le système devient :

$$x + 2y + 3z = 1$$

$$0x + \dots = \dots$$

$$0x + 0y + z = \dots$$

La complexité algorithmique de cette méthode est en $O(N^3)$.

2.2 Décomposition LU

L'objectif est d'écrire $A = LU$ où L est une matrice triangulaire inférieure (*Tri inf*) et U est une matrice triangulaire supérieure (*Tri sup*).

- **Multiplication à gauche :** On transforme A_1 en A_2 puis en A_3 par des matrices de transformation triangulaires inférieures B_n .

$$A_2 = \begin{pmatrix} 1 & & \\ -4 & 1 & \\ -7 & 0 & 1 \end{pmatrix} A_1$$

- **Construction :** $U = B_n B_{n-1} \dots B_1 A$.
- **Inversion :** $A = B_1^{-1} B_2^{-1} \dots B_n^{-1} U = LU$.

Cas pratique : On utilise souvent la forme $PA = LU$ où P est une matrice de permutation pour assurer la stabilité numérique. Pour résoudre $Ax = b$, on résout successivement :

1. $Ly = Pb$ (par descente).
2. $Ux = y$ (par remontée).

3 Factorisation Orthogonale et Cas Particuliers

3.1 Procédé de Gram-Schmidt

Soient $u_1, \dots, u_M \in \mathbb{C}^N$ des vecteurs avec $M \leq N$. On construit une base orthonormée $q_1, \dots, q_M$ telle que $Q^*Q = I_M$.

$$q_1 = \frac{u_1}{\|u_1\|}$$
$$q_2 = \frac{u_2 - \langle q_1, u_2 \rangle q_1}{\|u_2 - \langle q_1, u_2 \rangle q_1\|}$$

Chaque q_n est obtenu par combinaison linéaire de $u_1, \dots, u_n$. On peut alors écrire $Q = AR^{-1}$, soit $A = QR$.

3.2 Décomposition QR

$A = QR$ où Q est une matrice orthogonale ($Q^*Q = I$) et R est une matrice triangulaire supérieure. Pour résoudre $QRx = b$, on calcule $y = Q^*b$, puis on résout le système triangulaire $Rx = y$.

3.3 Décomposition de Cholesky

Si A est une matrice symétrique définie positive, elle admet une décomposition unique de la forme :

$$A = LL^T$$

4 Problèmes de Moindres Carrés

4.1 Approche Linéaire

On cherche à ajuster une droite $y = \alpha X + \beta$. Pour un ensemble de points (x_i, y_i) , on cherche $(\alpha, \beta) \in \mathbb{R}^2$ qui minimise :

$$\sum_{i=1}^N |y_i - (\alpha x_i + \beta)|^2$$

Soit $e_i = y_i - (\alpha x_i + \beta)$ le résidu. On veut minimiser $\|e\|^2 = \langle e, e \rangle$.

4.2 Formulation Matricielle

Le problème se généralise à $A \in \mathbb{R}^{N \times M}$ et $b \in \mathbb{R}^N$ avec $N \gg M$. On cherche x tel que :

$$\min_{x \in \mathbb{R}^M} \|Ax - b\|^2$$

Développons la norme au carré :

$$\begin{aligned}\|Ax - b\|^2 &= \langle Ax - b, Ax - b \rangle \\ &= (Ax)^T(Ax) - b^T Ax - (Ax)^T b + \|b\|^2 \\ &= x^T A^T Ax - 2(A^T b)^T x + \|b\|^2\end{aligned}$$

4.3 Équations Normales

En dérivant par rapport à x , on cherche le point où le gradient s'annule :

$$2A^T Ax - 2A^T b = 0$$

On obtient les **formes normales** :

$$A^T Ax = A^T b \tag{2}$$

5 Analyse de Convergence et Optimisation

5.1 Étude de la fonctionnelle $f(x) = \|Ax - b\|^2$

Soit $f(x) = \|Ax - b\|^2$. Calculons ses dérivées :

- **Gradient** : $\nabla f(x) = A^T Ax - A^T b$.
- **Hessienne** : $\nabla^2 f(x) = A^T A$. C'est la matrice de Gram.

Les éléments de la matrice de Gram sont $(A^T A)_{ij} = \langle a_i, a_j \rangle$, où a_i sont les colonnes de A .

Propriété : $A^T A$ est semi-définie positive. En effet :

$$x^T A^T Ax = (Ax)^T Ax = \|Ax\|^2 \geq 0$$

Si A est injective ($\ker A = \{0\}$), alors $\|Ax\|^2 = 0 \implies x = 0$, et $A^T A$ est définie positive.

5.2 Coercivité

Une fonction est dite coercive si $\lim_{\|x\| \rightarrow \infty} f(x) = +\infty$. Si A est injective, on a une "injectivité quantitative" : $\exists \beta > 0$ tel que $\|Ax\| \geq \beta \|x\|$. Alors :

$$f(x) \geq \beta^2 \|x\|^2 - C \|x\| + \|b\|^2$$

Ce qui prouve que f est coercive.

5.3 Unicité du Minimiseur

Preuve. Soient x et y deux minimiseurs de f . Considérons la fonction auxiliaire $\phi(t) = f(x + t(y - x))$. Comme x est un minimiseur, $\phi(0)$ est un minimum, donc $\phi'(0) = 0$. Calculons les dérivées :

$$\begin{aligned}\phi'(t) &= (y - x)^T \nabla f(x + t(y - x)) \\ \phi''(t) &= (y - x)^T \nabla^2 f(x + t(y - x))(y - x) = (y - x)^T (A^T A)(y - x)\end{aligned}$$

D'après l'injectivité quantitative :

$$\phi''(t) = \|A(y - x)\|^2 \geq \beta \|y - x\|^2$$

Si $x \neq y$, alors $\phi''(t) > 0$, ce qui implique que la fonction est strictement convexe et que le minimiseur est unique. $\square$




Figure 1: Représentation de la recherche d'unicité entre deux points x et y .