

Cours 1 - Introduction aux Modèles Statistiques, Estimateurs et Risque

Évaluation

- $0.4 \times \text{CC} + 0.6 \times \text{Examen}$
- Le CC est composé de : 80% pour le partiel et 20% pour l'interrogation du 26/01.

1 Modèle Statistique

Definition 1.1. Un modèle statistique est un espace de probabilité $(\Omega, \mathcal{A}, \mathcal{P})$ où $\mathcal{P}$ est une famille de lois de probabilité $\{P_\theta; \theta \in \Theta\}$.

- Si $\exists p \in \mathbb{N}^*, \Theta \subset \mathbb{R}^p$: le modèle est dit **paramétrique**.
- Sinon : le modèle est dit **non paramétrique**.

Example 1.2. Exemples de familles :

- $\mathcal{P} = \{\mathcal{P}(\lambda); \lambda > 0\}$ les lois de Poisson.
- $\mathcal{P} = \{\text{loi de probas}\} = \{P; P \text{ dont la densité admet une dérivée seconde bornée}\}$.

Definition 1.3. Une **observation** est une variable aléatoire (v.a.) dont la loi $\in \{P_\theta; \theta \in \Theta\}$. Notre observation aura une structure de n -échantillon $X_1, \dots, X_n$ des v.a. indépendantes (réelles) identiquement distribuées (i.i.d.), de loi commune $\in \{P_\theta; \theta \in \Theta\}$.

Remark 1.4. On note $(X_1, \dots, X_n)$ de loi $P_\theta^{\otimes n}$. L'échantillon contient toute l'information sur P_θ , donc sur θ .

Definition 1.5. Un modèle est dit **identifiable** si et seulement si l'application $\theta \longrightarrow P_\theta$ est injective.

Remark 1.6. Il ne faut pas confondre :

- X_i : la variable aléatoire.
- x_i : la donnée, qui est une réalisation de X_i .

2 Estimateurs

Hypothèse : On observe $X_1, \dots, X_n$ i.i.d. de loi commune $\in \{P_\theta, \theta \in \Theta \subset \mathbb{R}^p\}$, dans un modèle paramétrique identifiable. Il existe un θ^* inconnu tel que $P_{X_1} = P_{\theta^*}$.

Definition 2.1 (Estimateur). Un estimateur de θ est une fonction de l'échantillon $h(X_1, \dots, X_n)$, mesurable et indépendante de θ . Il doit être calculable à partir des données.

Notation : $\hat{\theta} = \hat{\theta}_n = h(X_1, \dots, X_n)$. On note que $\hat{\theta}_n$ est une variable aléatoire.

Example 2.2. $\hat{\theta} = 0, \hat{\theta} = X_1 - X_3, \dots$

Deux questions fondamentales se posent :

1. Comment définir un bon estimateur ?
2. Comment construire un bon estimateur ?

3 Risque quadratique

Idee : En moyenne, $\hat{\theta}$ doit être proche de θ . On s'intéresse à l'écart $(\hat{\theta} - \theta)$.

Definition 3.1 (Biais de $\hat{\theta}$). Le biais est défini par :

$$B(\hat{\theta}, \theta) = \mathbb{E}[\hat{\theta}] - \theta$$

On dit que $\hat{\theta}$ est **sans biais** si $B(\hat{\theta}, \theta) = 0$.

Definition 3.2 (Risque quadratique). Le risque quadratique, ou MSE (*mean squared error*), est défini par :

$$R(\hat{\theta}, \theta) = \mathbb{E}[(\hat{\theta} - \theta)^2]$$

On dit que $\hat{\theta}_1$ est meilleur que $\hat{\theta}_2$ si $R(\hat{\theta}_1, \theta) \leq R(\hat{\theta}_2, \theta)$.

Example 3.3 (Modèle de Poisson). Soient $X_1, \dots, X_n$ i.i.d. de loi P_θ de Poisson, $\theta > 0$. On cherche à estimer θ . On sait que $\theta = \mathbb{E}[X_1]$. Un estimateur naturel est la moyenne empirique :

$$\hat{\theta}_n = \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$




Figure 1: Illustration de la précision de deux estimateurs. L'estimateur $\hat{\theta}_1$ est plus concentré autour de la valeur réelle θ .

Calcul du biais :

$$\begin{aligned}
 B(\hat{\theta}, \theta) &= \mathbb{E} \left[\frac{1}{n} \sum_{i=1}^n X_i \right] - \theta \\
 &\quad (\text{par linéarité}) \\
 &= \frac{1}{n} \sum_{i=1}^n \mathbb{E}[X_i] - \theta \\
 &\quad (\text{v.a. i.i.d.}) \\
 &= \frac{1}{n} \cdot n \mathbb{E}[X_1] - \theta \\
 &= \mathbb{E}[X_1] - \theta = \theta - \theta = 0
 \end{aligned}$$

Ainsi, $\mathbb{E}[\bar{X}] = \theta$, l'estimateur est sans biais.

Calcul du risque quadratique :

$$\begin{aligned}
 R(\hat{\theta}, \theta) &= \mathbb{E} [(\bar{X} - \theta)^2] = \mathbb{E} [(\bar{X} - \mathbb{E}[\bar{X}])^2] \\
 &= \text{Var}(\bar{X}) \\
 &= \text{Var} \left(\frac{1}{n} \sum X_i \right) \\
 &= \frac{1}{n^2} \text{Var} \left(\sum X_i \right) \\
 &\quad (\text{par indépendance}) \\
 &= \frac{1}{n^2} \sum \text{Var}(X_i) = \frac{1}{n^2} \cdot n \cdot \text{Var}(X_1) = \frac{\text{Var}(X_1)}{n}
 \end{aligned}$$

Pour une loi de Poisson, $\text{Var}(X_1) = \theta$, donc $R(\hat{\theta}, \theta) = \frac{\theta}{n}$.

Proposition 3.4 (Décomposition biais-variance du risque).

$$R(\hat{\theta}, \theta) = (B(\hat{\theta}, \theta))^2 + \text{Var}(\hat{\theta})$$

Preuve.

$$\begin{aligned} R(\hat{\theta}, \theta) &= \mathbb{E} \left[(\hat{\theta} - \theta)^2 \right] \\ &\stackrel{\text{def}}{=} \mathbb{E} \left[(\hat{\theta} - \mathbb{E}[\hat{\theta}] + \mathbb{E}[\hat{\theta}] - \theta)^2 \right] \\ &= \mathbb{E} \left[(\hat{\theta} - \mathbb{E}[\hat{\theta}])^2 + (\mathbb{E}[\hat{\theta}] - \theta)^2 + 2(\hat{\theta} - \mathbb{E}[\hat{\theta}])(\mathbb{E}[\hat{\theta}] - \theta) \right] \\ &= \text{Var}(\hat{\theta}) + (B(\hat{\theta}, \theta))^2 + 2B(\hat{\theta}, \theta) \underbrace{\mathbb{E}[\hat{\theta} - \mathbb{E}[\hat{\theta}]]}_{=0} \\ &= \text{Var}(\hat{\theta}) + (B(\hat{\theta}, \theta))^2 \end{aligned}$$

□

4 Consistance

Il s'agit d'une propriété asymptotique. En statistique, on ne considère généralement que des estimateurs consistants.

Definition 4.1. Soit $(X_1, \dots, X_n)$ i.i.d. de loi $P_\theta, \theta \in \Theta \subset \mathbb{R}^p$. Soit $\hat{\theta}_n = h(X_1, \dots, X_n)$. On considère la suite de v.a. $(\hat{\theta}_n)_{n \geq 1}$. $\hat{\theta}_n$ est un estimateur **consistant** (ou convergent) de θ si :

$$\hat{\theta}_n \xrightarrow[n \rightarrow +\infty]{P_\theta} \theta$$

Remark 4.2. $(\hat{\theta}_n)$ est **fortement consistant** si :

$$\hat{\theta}_n \xrightarrow[n \rightarrow +\infty]{p.s.} \theta$$

Example 4.3 (Modèle de Poisson). $\theta = \mathbb{E}[X_1]$; $\hat{\theta}_n = \bar{X}$.

- On peut invoquer la Loi des Grands Nombres (LGN) : $\bar{X} \xrightarrow{P} \mathbb{E}[X_1] = \theta$.
- $R(\hat{\theta}, \theta) = \text{Var}(\bar{X}) = \frac{\theta}{n} \xrightarrow[n \rightarrow +\infty]{} 0$.
- Par l'inégalité de Bienaymé-Tchebychev (BT) :

$$\forall \epsilon > 0, P(|\hat{\theta} - \theta| > \epsilon) \leq \frac{\mathbb{E}[|\hat{\theta} - \theta|^2]}{\epsilon^2} = \frac{R(\hat{\theta}, \theta)}{\epsilon^2} \xrightarrow[n \rightarrow +\infty]{} 0$$

- Soient $(X_1, \dots, X_n)$ i.i.d. $\text{Poisson}(\theta)$.
- On veut estimer $\beta = P(X_i = 0) = e^{-\theta}$.

- Par la méthode "plug-in" : $\hat{\beta} = e^{-\hat{\theta}} = e^{-\bar{X}}$.
- $\hat{\beta}$ est consistant pour estimer β grâce au lemme suivant.

Lemma 4.4 (de l'application continue). Si $Z_n \xrightarrow{P} Z$, alors $h(Z_n) \xrightarrow{P} h(Z)$ pour toute fonction h continue.

fin cours 05/01/26