

# CM2 : Le Cadre Paramétrique et Méthodes d'Estimation

---

## 1 Le Cadre Paramétrique

Dans ce chapitre, nous abordons l'estimation statistique dans un contexte paramétrique.

**Definition 1.1** (Modèle statistique paramétrique). On dispose d'une observation  $(X_1, \dots, X_n)$  constituant un échantillon de variables aléatoires indépendantes et identiquement distribuées (i.i.d.) de loi commune  $P$  appartenant à une famille de lois de probabilités paramétrée :

$$\{P_\theta, \theta \in \Theta \subset \mathbb{R}^p\}$$

**Remark 1.2.** Si l'espace des paramètres  $\Theta$  est de dimension infinie, on parle alors de modèle **non-paramétrique**.

**Problématique :** Estimer la loi  $P$  revient à estimer le paramètre inconnu  $\theta \in \mathbb{R}^p$ .

**Example 1.3.** Voici quelques exemples classiques de modèles paramétriques :

- Loi de Bernoulli :  $\text{Bern}(\theta)$
- Loi Normale :  $\mathcal{N}(\mu, \sigma^2)$
- Loi de puissance :  $f_\theta(x) = \theta x^{\theta-1} \mathbb{1}_{x \in [0,1]}$
- Loi Exponentielle :  $\text{Exp}(\theta)$

**Notations :**

- $E_\theta[h(X_1, \dots, X_n)]$  désigne l'espérance sous la loi  $P_\theta$ .
- La loi du vecteur  $(X_1, \dots, X_n)$  est notée  $P_\theta^{\otimes n}$ .

**Definition 1.4** (Estimateur). Un estimateur de  $\theta$  est une fonction des observations :

$$\hat{\theta} = \hat{\theta}_n = h(X_1, \dots, X_n)$$

**Qualité d'un estimateur :** Pour évaluer la performance d'un estimateur, on utilise principalement deux critères :

1. **Risque quadratique** :  $R(\hat{\theta}, \theta) = E[(\hat{\theta} - \theta)^2]$
2. **Consistance** : L'estimateur est dit consistant si  $\hat{\theta}_n \xrightarrow[n \rightarrow \infty]{P} \theta$  (convergence en probabilité).

**Definition 1.5** (Modèle identifiable). Un modèle est dit identifiable si l'application  $\theta \rightarrow P_\theta$  est injective.

## 2 La Méthode des Moments (MM)

**Definition 2.1.** Soit  $k \geq 1$ . On définit :

- Le **moment théorique** d'ordre  $k$  de la loi des  $X_i$  :  $M_k = E[X_i^k]$ .
- Le **moment empirique** d'ordre  $k$  de la loi des  $X_i$  :  $\hat{M}_k = \frac{1}{n} \sum_{i=1}^n X_i^k$ .

D'après la **Loi des Grands Nombres (LGN)**, on a la convergence suivante :

$$\hat{M}_k \xrightarrow[n \rightarrow \infty]{P} M_k$$

**Principe de la méthode :** Si l'on peut exprimer le paramètre d'intérêt  $\theta$  (ou une fonction  $g(\theta)$ ) comme une fonction  $\varphi$  des  $k$  premiers moments théoriques :

$$\theta = \varphi(M_1, \dots, M_k)$$

Alors, l'estimateur par la méthode des moments est obtenu en remplaçant les moments théoriques par les moments empiriques :

$$\hat{\theta} = \varphi(\hat{M}_1, \dots, \hat{M}_k)$$

**Example 2.2** (Loi de Bernoulli). Soit  $X_i \sim \text{Ber}(\theta)$ . On a  $\theta = P(X_i = 1) = E[X_i]$ . Le moment théorique est  $M_1 = E[X_i]$ . L'estimateur est donc :

$$E[X_i] \rightsquigarrow \frac{1}{n} \sum_{i=1}^n X_i = \bar{X} \implies \hat{\theta} = \bar{X}$$

**Example 2.3** (Loi Exponentielle). Soit  $X_i \sim \text{Exp}(\theta)$  de densité  $f_\theta(x) = \theta e^{-\theta x} \mathbb{1}_{x \geq 0}$ . On sait que  $M_1 = E[X_1] = \frac{1}{\theta}$ , d'où  $\theta = \frac{1}{M_1}$ . L'estimateur des moments est :

$$\hat{\theta} = \frac{1}{\hat{M}_1} = \frac{1}{\bar{X}}$$

**Example 2.4** (Loi de puissance). Soient  $X_1, \dots, X_n$  i.i.d. de loi  $P_\theta$  de densité  $f_\theta(x) = \theta x^{\theta-1} \mathbb{1}_{x \in [0,1]}$  avec  $\theta > 0$ . Calculons le premier moment théorique :

$$\begin{aligned} M_1 = E[X] &= \int_0^1 x \cdot \theta x^{\theta-1} dx = \theta \int_0^1 x^\theta dx \\ &= \theta \left[ \frac{x^{\theta+1}}{\theta+1} \right]_0^1 = \frac{\theta}{\theta+1} \end{aligned}$$

On isole  $\theta$  :

$$\begin{aligned} (\theta + 1)M_1 = \theta &\iff \theta M_1 + M_1 = \theta \\ &\iff \theta(1 - M_1) = M_1 \\ &\iff \theta = \frac{M_1}{1 - M_1} \end{aligned}$$

L'estimateur des moments est :

$$\hat{\theta}_M = \frac{\bar{X}}{1 - \bar{X}}$$

Note : Si  $\bar{X} = 1$ , l'estimateur n'est pas défini. Cependant,  $P_\theta(\bar{X} = 1) = P_\theta(X_1 = X_2 = \dots = X_n = 1) = 0$ .

### 3 Le Lemme d'Application Continue (LAC)

Une question fondamentale est de savoir si l'estimateur des moments est consistant. Pour cela, on utilise le Lemme d'Application Continue.

**Lemma 3.1 (Lemme d'Application Continue - LAC).** Soit  $(X_n)_{n \geq 1}$  une suite de variables aléatoires. Si  $X_n \xrightarrow{P} X$  et si  $g$  est une fonction continue, alors :

$$g(X_n) \xrightarrow{P} g(X)$$

De même, si  $X_n \xrightarrow{\mathcal{L}} X$ , alors  $g(X_n) \xrightarrow{\mathcal{L}} g(X)$ .

**Remark 3.2.** Une condition suffisante de continuité en présence de points de discontinuité  $D_g$  est  $P(X \in D_g) = 0$ .

**Example 3.3.** Pour l'exemple précédent  $g(x) = \frac{x}{1-x}$ . Par la LGN,  $\bar{X} \xrightarrow{P} E[X]$ . Par le LAC, si  $g$  est continue en  $E[X]$ , alors  $g(\bar{X}) \xrightarrow{P} g(E[X]) = \theta$ . L'estimateur est donc consistant.

**LAC pour des couples :** Soient  $(X_n, Y_n)$  des suites de variables aléatoires.

- Si  $(X_n, Y_n) \xrightarrow{P} (X, Y)$  et si  $g : \mathbb{R}^2 \rightarrow \mathbb{R}$  est continue, alors  $g(X_n, Y_n) \xrightarrow{P} g(X, Y)$ .
- Si  $(X_n, Y_n) \xrightarrow{\mathcal{L}} (X, Y)$ , alors  $g(X_n, Y_n) \xrightarrow{\mathcal{L}} g(X, Y)$ .

**Remark 3.4.** La convergence des couples est équivalente à la convergence de chaque composante pour la probabilité :

$$(X_n, Y_n) \xrightarrow{P} (X, Y) \iff X_n \xrightarrow{P} X \text{ et } Y_n \xrightarrow{P} Y$$

**Attention :** Cette réciproque est fausse pour la convergence en loi !

### 4 Étude de la Variance Empirique

Si les  $X_i$  admettent une espérance  $\mu$  et une variance  $\sigma^2$ , on appelle **variance empirique** :

$$\hat{\sigma}_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$$

En développant, on obtient :

$$\begin{aligned}\hat{\sigma}_n^2 &= \frac{1}{n} \sum X_i^2 + \frac{1}{n} \sum \bar{X}^2 - \frac{2}{n} \sum X_i \bar{X} \\ &= \frac{1}{n} \sum X_i^2 + \bar{X}^2 - 2\bar{X} \bar{X} \\ &= \frac{1}{n} \sum X_i^2 - (\bar{X})^2 = \tilde{\sigma}^2\end{aligned}$$

**Estimateur des moments :** Puisque  $\sigma^2 = E[X^2] - (E[X])^2$ , on remplace les moments théoriques par les moments empiriques :

$$\hat{\sigma}_{MM}^2 = \frac{1}{n} \sum X_i^2 - (\bar{X})^2$$

**Consistance :** D'après la LGN :

- $\bar{X} \xrightarrow{P} E[X]$
- $\frac{1}{n} \sum X_i^2 \xrightarrow{P} E[X^2]$

Ainsi, le couple des moments empiriques converge :

$$\left( \frac{1}{n} \sum X_i^2 \right) \xrightarrow{P} \left( \begin{matrix} E[X] \\ E[X^2] \end{matrix} \right)$$

En utilisant le LAC avec  $g(x, y) = y - x^2$  (qui est continue de  $\mathbb{R}^2 \rightarrow \mathbb{R}$ ), on en déduit que :

$$\hat{\sigma}_n^2 \xrightarrow{P} E[X^2] - (E[X])^2 = \text{Var}(X)$$

L'estimateur  $\hat{\sigma}_n^2$  est donc consistant pour la variance  $\sigma^2$ .

**Remark 4.1.** Exercice : Calculer le biais et le risque de  $\hat{\sigma}_n^2$ .

## 5 Méthode du Maximum de Vraisemblance (MV)

**Definition 5.1** (Modèle dominé). Un modèle  $(P_\theta)_{\theta \in \Theta}$  est dit dominé s'il existe une mesure  $\nu$  (positive  $\sigma$ -finie) telle que pour tout  $\theta$ ,  $P_\theta$  admette une densité  $f_\theta$  par rapport à  $\nu$ .

En pratique :

- Si l'espace  $E$  est au plus dénombrable,  $\nu$  est la **mesure de comptage**. Si  $\exists \{a_1, a_2, \dots\}$  tel que  $\sum_{k \geq 1} P_\theta(X_i = a_k) = 1$ , alors  $\nu = \sum \delta_{a_k}$  avec  $\delta_a(\{a\}) = 1$  (mesure de Dirac). On écrira  $f_\theta(x) = P_\theta(\bar{X}_i = x)$ .
- Si  $E = \mathbb{R}^p$ , alors  $f_\theta$  est la densité usuelle (par rapport à la mesure de Lebesgue).

**Definition 5.2** (Vraisemblance). On appelle **vraisemblance** de l'échantillon  $(X_1, \dots, X_n)$  (Likelihood) la fonction :

$$\theta \rightarrow L_n(\theta) = \prod_{i=1}^n f_\theta(X_i)$$

C'est une variable aléatoire car elle dépend de l'échantillon.

**Definition 5.3** (Estimateur du Maximum de Vraisemblance). Un estimateur du maximum de vraisemblance  $\hat{\theta}_{MV}$  est défini tel que :

$$\forall \theta \in \Theta, \quad L_n(\theta) \leq L_n(\hat{\theta}_{MV})$$

On travaille souvent avec la **log-vraisemblance** car elle transforme le produit en somme, ce qui facilite les calculs :

$$\log L_n(\theta) = \sum_{i=1}^n \ln f_\theta(X_i)$$

Puisque le logarithme est une fonction croissante, maximiser  $L_n$  revient à maximiser  $\log L_n$  :

$$\log L_n(\hat{\theta}) = \sup_{\theta \in \Theta} \log L_n(\theta)$$

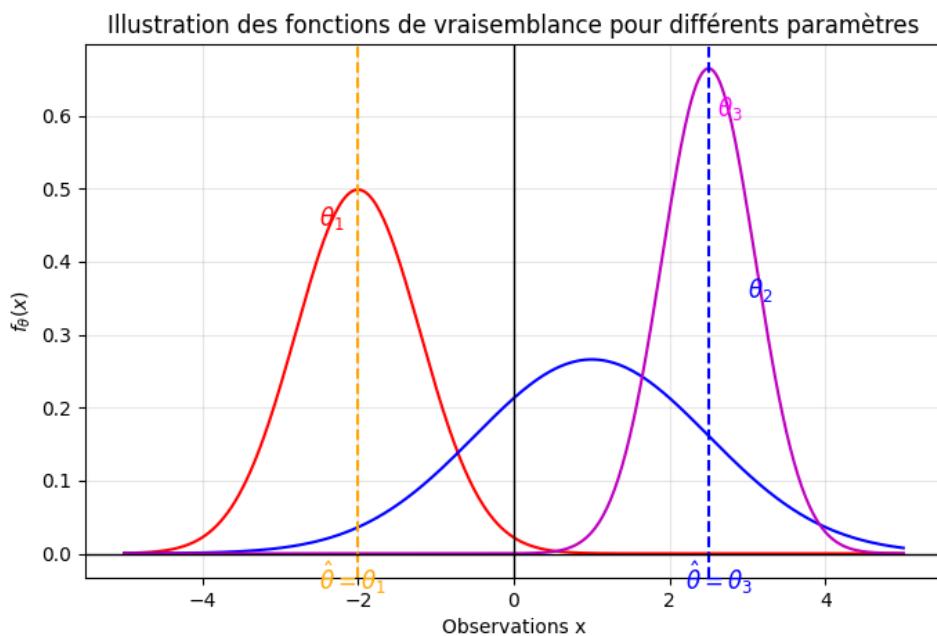


Figure 1: Comparaison des vraisemblances pour différentes valeurs de  $\theta$ . L'estimateur du maximum de vraisemblance choisit le paramètre qui maximise la probabilité d'observer les données.

## 6 Mise en œuvre du MV : Exemple de la loi de Bernoulli

Soit  $X_i \sim \text{Ber}(\theta)$ , la densité est  $f_\theta(x) = \theta^x(1-\theta)^{1-x}$  pour  $x \in \{0, 1\}$ . La vraisemblance est :

$$L_n(\theta) = \prod_{i=1}^n \theta^{X_i}(1-\theta)^{1-X_i} = \theta^{\sum X_i}(1-\theta)^{n-\sum X_i}$$

La log-vraisemblance s'écrit :

$$\log L_n(\theta) = \left(\sum X_i\right) \ln \theta + \left(n - \sum X_i\right) \ln(1-\theta)$$

**Condition du premier ordre (Point critique) :** On dérive par rapport à  $\theta$  :

$$(\log L_n)'(\theta) = \frac{\sum X_i}{\theta} - \frac{n - \sum X_i}{1 - \theta}$$

Recherchons le point critique où la dérivée s'annule :

$$\begin{aligned} (\log L_n)'(\theta) = 0 &\iff \frac{\sum X_i}{\theta} = \frac{n - \sum X_i}{1 - \theta} \\ &\iff (1 - \theta) \sum X_i = \theta(n - \sum X_i) \\ &\iff \sum X_i - \theta \sum X_i = n\theta - \theta \sum X_i \\ &\iff \sum X_i = n\theta \\ &\iff \theta = \frac{\sum X_i}{n} = \bar{X} \end{aligned}$$

On peut aussi réécrire la dérivée sous la forme :

$$(\log L_n)'(\theta) = \frac{\sum X_i - n\theta}{\theta(1 - \theta)} = \frac{n}{\theta(1 - \theta)}(\bar{X} - \theta)$$

La dérivée change de signe en  $\bar{X}$  (de positif à négatif), donc on a bien un maximum en  $\hat{\theta}_{MV} = \bar{X}$ .

**Condition du second ordre :** Pour confirmer qu'il s'agit d'un maximum global, on vérifie la concavité de la log-vraisemblance en calculant la dérivée seconde :

$$(\log L_n)''(\theta) = -\frac{\sum X_i}{\theta^2} - \frac{n - \sum X_i}{(1 - \theta)^2}$$

Puisque  $\sum X_i \geq 0$  et  $n - \sum X_i \geq 0$ , on a  $(\log L_n)''(\theta) < 0$  pour tout  $\theta \in ]0, 1[$ . La fonction est donc strictement concave, ce qui garantit que le maximum est unique et global.

**Conclusion :** Par unicité du point critique et concavité de la fonction,  $\hat{\theta} = \bar{X}$  est l'unique Estimateur du Maximum de Vraisemblance (E.M.V.).