

CM3 : Information de Fisher et Efficacité

1 Introduction au Modèle Régulier

Dans ce chapitre, nous étudions les propriétés de l'information contenue dans un échantillon concernant un paramètre inconnu θ . Nous nous plaçons dans le cadre d'un modèle statistique $(P_\theta)_{\theta \in \Theta}$ avec $\Theta \subset \mathbb{R}^p$. Nous supposons que le modèle est identifiable et dominé par une mesure μ .

- On note f_θ la densité de P_θ par rapport à μ .
- Le support de la densité est défini par $Supp_\theta = \{x \in E, f_\theta(x) > 0\}$.
- Étant donné un échantillon $(X_1, \dots, X_n)$ i.i.d. de loi P_θ , on note $L_n(\theta)$ la vraisemblance de l'échantillon :

$$L_n(\theta) = \prod_{i=1}^n f_\theta(x_i)$$

- Sur le support, on peut calculer la log-vraisemblance :

$$\log L_n(\theta) = \sum_{i=1}^n \log f_\theta(x_i)$$

- L'estimateur du maximum de vraisemblance (EMV) est défini par :

$$\hat{\theta} = \text{Argmax}_{\theta \in \Theta} \log L_n(\theta)$$

Proposition 1.1 (Propriété d'invariance de l'EMV). Si $\hat{\theta}$ est l'EMV de θ , alors $g(\hat{\theta})$ est un EMV de $g(\theta)$.

Objectif : Peut-on avoir "mieux" comme estimateur ? Pour répondre à cela, nous devons définir un cadre de régularité.

1.1 Définition du Modèle Régulier

Definition 1.2. Le modèle $(P_\theta)_{\theta \in \Theta}$ est dit **régulier** si :

- Θ est un ouvert et pour tout $x \in E$, l'application $\theta \mapsto f_\theta(x)$ est de classe C^1 .
- Le support de la densité ne dépend pas de θ : $S = \{x, f_\theta(x) > 0\}$.
- Pour tout θ , l'application $x \mapsto \frac{\left(\frac{\partial f_\theta(x)}{\partial \theta}\right)^2}{f_\theta(x)} \mathbb{1}_{f_\theta(x) > 0}$ est intégrable ($L_1(\mu)$).

On définit alors l'Information de Fisher du modèle par :

$$I(\theta) = \int_S \frac{\left(\frac{\partial f_\theta(x)}{\partial \theta}\right)^2}{f_\theta(x)} dx$$

On suppose également que $I(\theta)$ est continue sur Θ .

Notation : On note souvent la dérivée de $f_\theta(x)$ par rapport à θ par $\partial_\theta f_\theta(x)$.

Exemple 1.3 (Loi Exponentielle). Soit $f_\theta(x) = \theta e^{-x\theta} \mathbb{1}_{x \geq 0}$ avec $\theta \in \Theta =]0, +\infty[$.

- L'application $\theta \mapsto \theta e^{-x\theta}$ est C^∞ .
- Le support est $\text{Supp} f_\theta = \mathbb{R}^+$, qui ne dépend pas de θ .
- Dérivée : $\frac{\partial f_\theta}{\partial \theta}(x) = (1 - x\theta)e^{-x\theta}$.
- On calcule : $\frac{\left(\frac{\partial f_\theta(x)}{\partial \theta}\right)^2}{f_\theta(x)} = \frac{(1-x\theta)^2(e^{-x\theta})^2}{\theta e^{-x\theta}} = \frac{(1-x\theta)^2 e^{-x\theta}}{\theta}$.

Si $X \sim \mathcal{E}(\theta)$, on sait que $E[X^k] = \frac{k!}{\theta^k}$. Calculons $I(\theta)$:

$$\begin{aligned} I(\theta) &= \int_0^\infty \frac{(1-x\theta)^2}{\theta^2} \theta e^{-x\theta} dx = \frac{1}{\theta^2} E_\theta[(1-X\theta)^2] \\ &= \frac{1}{\theta^2} E_\theta[1 - 2\theta X + \theta^2 X^2] = \frac{1}{\theta^2} [1 - 2\theta E[X] + \theta^2 E[X^2]] \\ &= \frac{1}{\theta^2} [1 - 2\theta \frac{1}{\theta} + \theta^2 \frac{2}{\theta^2}] = \frac{1}{\theta^2} [1 - 2 + 2] = \frac{1}{\theta^2} \end{aligned}$$

Cette quantité est bien continue sur $]0, +\infty[$.

2 Information de Fisher et Score

2.1 Exemples complémentaires

Exemple 2.1 (Loi de Bernoulli $\mathcal{B}(\theta)$). $X \in \{0, 1\}$. $f_\theta(0) = 1 - \theta$ et $f_\theta(1) = \theta$ par rapport à la mesure $\delta_0 + \delta_1$. Pour $x \in \{0, 1\}$, $\theta \mapsto f_\theta(x)$ est C^1 .

- $\frac{(\partial_\theta f_\theta(0))^2}{f_\theta(0)} = \frac{(-1)^2}{1-\theta} = \frac{1}{1-\theta}$
- $\frac{(\partial_\theta f_\theta(1))^2}{f_\theta(1)} = \frac{1^2}{\theta} = \frac{1}{\theta}$

D'où $I(\theta) = \frac{1}{1-\theta} + \frac{1}{\theta} = \frac{1}{\theta(1-\theta)}$, continue sur $]0, 1[$.

Exemple 2.2 (Modèle non régulier). Soit $f_\theta(x) = \frac{1}{\theta} \mathbb{1}_{[0, \theta]}(x)$. Ici, le support $[0, \theta]$ dépend explicitement de θ . Le modèle n'est pas régulier au sens de la définition précédente.

2.2 Vecteur de Score

Définition 2.3. Soit $(X_1, \dots, X_n)$ i.i.d. de loi P_θ . On appelle **score** (ou vecteur de score) la dérivée de

la log-vraisemblance :

$$S_n(\theta) = \frac{\partial}{\partial \theta} \log L_n(\theta) = \sum_{i=1}^n \frac{\partial}{\partial \theta} \log f_\theta(X_i)$$

Exemple 2.4. Pour $X_i \sim \mathcal{E}(\theta) : L_n(\theta) = \theta^n e^{-\theta \sum x_i} \implies \log L_n(\theta) = n \log \theta - \theta \sum x_i$. Alors $S_n(\theta) = \frac{n}{\theta} - \sum_{i=1}^n X_i$.

Remark 2.5. On remarque que $E[S_n(\theta)] = E[n(\frac{1}{\theta} - \bar{X}_n)] = n(\frac{1}{\theta} - \frac{1}{\theta}) = 0$. Le score semble être centré.

2.3 Hypothèse supplémentaire de régularité

Nous introduisons l'hypothèse (H) : pour tout estimateur $h(X)$ et tout θ , les intégrales suivantes existent et on peut intervertir dérivation et intégration :

$$(H) : \frac{\partial}{\partial \theta} \int_S h(x) f_\theta(x) dx = \int_S h(x) \frac{\partial f_\theta}{\partial \theta}(x) dx$$

Remark 2.6. C'est la condition d'application du théorème de domination de Lebesgue. Typiquement, on demande $h \sup_{\theta \in \Theta} |\frac{\partial f_\theta}{\partial \theta}(x)| \in L_1(\mu)$.

Proposition 2.7. Sous l'hypothèse (H), le score est centré : $E_\theta[S_n(\theta)] = 0$.

Preuve. Pour $n = 1$:

$$E_\theta \left[\frac{\partial}{\partial \theta} \log f_\theta(X) \right] = \int_S \frac{\frac{\partial f_\theta(x)}{\partial \theta}}{f_\theta(x)} f_\theta(x) dx = \int_S \frac{\partial f_\theta}{\partial \theta}(x) dx \stackrel{(H)}{=} \frac{\partial}{\partial \theta} \left(\int_S f_\theta(x) dx \right) = \frac{\partial}{\partial \theta} (1) = 0$$

□

3 Information de Fisher pour un échantillon

Definition 3.1. L'information de Fisher associée à un échantillon $(X_1, \dots, X_n)$ est définie par :

$$I_n(\theta) \stackrel{\text{déf}}{=} E_\theta \left[\left(\frac{\partial}{\partial \theta} \log L_n(\theta) \right)^2 \right]$$

D'après la proposition précédente ($E[S_n] = 0$), cela correspond à la variance du score :

$$I_n(\theta) = \text{Var}_\theta \left(\frac{\partial}{\partial \theta} \log L_n(\theta) \right)$$

Exemple 3.2. Pour $X_1, \dots, X_n \sim \mathcal{E}(\theta) : \frac{\partial}{\partial \theta} \log L_n(\theta) = \frac{n}{\theta} - \sum X_i$.

$$I_n(\theta) = E \left[\left(\frac{n}{\theta} - \sum X_i \right)^2 \right] = n^2 E \left[\left(\frac{1}{\theta} - \bar{X} \right)^2 \right] = n^2 \text{Var}(\bar{X}) = n^2 \frac{1}{n} \text{Var}(X_1) = n \frac{1}{\theta^2}$$

Proposition 3.3. $I_n(\theta) = nI(\theta)$.

Preuve. $I_n(\theta) = \text{Var} \left(\frac{\partial}{\partial \theta} \log L_n(\theta) \right) = \text{Var} \left(\sum_{i=1}^n \frac{\partial}{\partial \theta} \log f_\theta(X_i) \right)$. Par indépendance des X_i , les variables $\frac{\partial}{\partial \theta} \log f_\theta(X_i)$ sont indépendantes, donc :

$$I_n(\theta) = \sum_{i=1}^n \text{Var} \left(\frac{\partial}{\partial \theta} \log f_\theta(X_i) \right) = n \text{Var} \left(\frac{\partial}{\partial \theta} \log f_\theta(X_1) \right) = nI(\theta)$$

□

Exemple 3.4. $(X_1, \dots, X_n)$ i.i.d. $\text{Poisson}(\theta)$. $f_\theta(x) = e^{-\theta} \frac{\theta^x}{x!}$. $\log L_n(\theta) = -n\theta + (\sum X_i) \log \theta - \log \prod X_i!$. $\frac{\partial}{\partial \theta} \log L_n(\theta) = -n + \frac{\sum X_i}{\theta} \implies I_n(\theta) = \text{Var} \left(\frac{\sum X_i}{\theta} \right) = \frac{1}{\theta^2} n\theta = \frac{n}{\theta}$.

4 Information de Fisher et Dérivée Seconde

Proposition 4.1. En ajoutant l'hypothèse que $\theta \mapsto f_\theta(x)$ est de classe C^2 et que (H) s'applique à la dérivée seconde, l'information de Fisher peut s'écrire :

$$I_n(\theta) = -E_\theta \left[\frac{\partial^2}{\partial \theta^2} \log L_n(\theta) \right]$$

Preuve. Pour $n = 1$:

$$\frac{\partial^2}{\partial \theta^2} \log f_\theta(x) = \frac{\frac{\partial^2 f_\theta(x)}{\partial \theta^2}}{f_\theta(x)} - \left(\frac{\frac{\partial f_\theta(x)}{\partial \theta}}{f_\theta(x)} \right)^2$$

En prenant l'espérance :

$$E \left[\frac{\partial^2}{\partial \theta^2} \log f_\theta(X) \right] = \underbrace{\int_S \frac{\partial^2 f_\theta(x)}{\partial \theta^2} dx}_{=0 \text{ par (H)}} - \underbrace{\int_S \left(\frac{\partial \log f_\theta}{\partial \theta} \right)^2 f_\theta(x) dx}_{=I(\theta)}$$

On a bien $E[\partial_\theta^2 \log f_\theta] = -I(\theta)$.

□

Interprétation graphique : L'information de Fisher mesure la courbure de la log-vraisemblance au point $\hat{\theta}$. Si la courbe est très "piquée", l'information de Fisher est grande et l'EMV est localisé de façon précise.

5 Inégalité de Cramér-Rao et Efficacité

Soit $g(\theta)$ le paramètre d'intérêt où $g : \Theta \rightarrow \mathbb{R}$.

Proposition 5.1. Sous les hypothèses d'un modèle régulier, si pour tout θ , $I(\theta) > 0$, alors pour tout




Figure 1: Lien entre la courbure de la log-vraisemblance et l'Information de Fisher.

estimateur $T = T(X_1, \dots, X_n)$ sans biais ($E_\theta[T] = g(\theta)$) et de variance finie, on a :

$$\forall \theta \in \Theta, \text{Var}_\theta(T) \geq \frac{(g'(\theta))^2}{I_n(\theta)} = \frac{(g'(\theta))^2}{nI(\theta)}$$

Preuve. $\forall \theta, E_\theta(T) = g(\theta) \implies \frac{\partial}{\partial \theta} E_\theta(T) = g'(\theta)$. En supposant (H) et pour $n = 1$ (généralisable) :

$$\begin{aligned} \frac{\partial}{\partial \theta} \int_S T(x) f_\theta(x) dx &= g'(\theta) \\ \int_S T(x) \frac{\partial f_\theta}{\partial \theta}(x) dx &= g'(\theta) \\ \int_S T(x) \frac{\partial_\theta f_\theta(x)}{f_\theta(x)} f_\theta(x) dx &= g'(\theta) \\ \int_S (T(x) - g(\theta)) \frac{\partial_\theta f_\theta(x)}{f_\theta(x)} f_\theta(x) dx &= g'(\theta) \quad (\text{car } E[S] = 0) \end{aligned}$$

En appliquant l'inégalité de Cauchy-Schwarz pour le produit scalaire $\langle h_1, h_2 \rangle = \int h_1(x) h_2(x) f_\theta(x) dx$:

$$(g'(\theta))^2 = \left(\int_S (T(x) - g(\theta)) \frac{\partial_\theta f_\theta(x)}{f_\theta(x)} f_\theta(x) dx \right)^2 \leq \int_S (T(x) - g(\theta))^2 f_\theta(x) dx \cdot \int_S \left(\frac{\partial_\theta f_\theta(x)}{f_\theta(x)} \right)^2 f_\theta(x) dx$$

On reconnaît les termes :

$$(g'(\theta))^2 \leq \text{Var}_\theta(T) \cdot I(\theta)$$

D'où $\text{Var}_\theta(T) \geq \frac{(g'(\theta))^2}{I(\theta)}$. □

Definition 5.2. Si un estimateur sans biais T réalise l'égalité dans la borne de Cramér-Rao, alors T est dit **efficace**.