



* Evaluation: 0.4CC + 0.6 examen
 ↑ 80% partiel, 20% Interro 26/01

1. Modèle Statistique

DEF: un modèle statistique est un espace de proba $(\Omega, \mathcal{F}, P)$ où P est une famille de loi de proba $\{P_\theta; \theta \in \Theta\}$
 si $\exists p \in \mathbb{N}^*$, $\Theta \subset \mathbb{R}^p$: modèle paramétrique

sinon: modèle non paramétrique

Exemples de familles: $\mathcal{P} = \{P(\lambda); \lambda > 0\}$ les lois de poisson

$\mathcal{P} = \{P \text{ loi de probas}\} = \{P; P \text{ dont la densité admet une dérivée seconde bornée}\}$

DEF: une observation est une v.a. dont la loi $\in \{P_\theta, \theta \in \Theta\}$

Notre observation aura une structure de n-échantillons $X_1, \dots, X_n$ des v.a. indep (réelles) identiquement distribuées, de loi commune $\in \{P_\theta, \theta \in \Theta\}$

Rq: $(X_1, \dots, X_n)$ de loi $P_\theta^{\otimes n}$

↳ l'échantillon contient toute l'info sur P_θ , donc sur θ .

DEF: un modèle est identifiable ssi $\theta \mapsto P_\theta$ est injective

Rq:
 observation $\begin{cases} \rightarrow X_i \text{ v.a.} \\ \rightarrow x_i = \text{donnée} \leadsto \text{réalisation de } X_i \end{cases}$

2. Estimateurs

Hyp: On observe $X_1, \dots, X_n$ i.i.d. de loi commune $\in \{P_\theta, \theta \in \Theta \subset \mathbb{R}^p\}$ modèle paramétrique identifiable
 ($\exists \theta^*$ inconnu tq $P_{X_i} = P_{\theta^*}$)

DEF: [estimateur] un estimateur de θ est une fonction de l'échantillon $(X_1, \dots, X_n)$ (mesurable) indep de θ
 (calculable à partir des données)

Notation: $\hat{\theta} = \hat{\theta}_n = h(X_1, \dots, X_n)$. ($\hat{\theta}_n$ est une v.a.)

Ex: $\hat{\theta} = 0$, $\hat{\theta} = X_1 - X_3 \dots$

↳ 1) Comment définir un bon estimateur?

2) Comment construire un bon estimateur?

3. Risque quadratique

Idée: En moyenne, $\hat{\theta}$ doit être proche de $\theta \rightarrow \mathbb{E}(\hat{\theta} - \theta)$

DEF: [biais de $\hat{\theta}$]

$$B(\hat{\theta}, \theta) = \mathbb{E}[\hat{\theta}] - \theta$$


On dit que $\hat{\theta}$ est sans biais si $B(\hat{\theta}, \theta) = 0$

DEF: [Risque quadratique]

$$R(\hat{\theta}, \theta) = \mathbb{E}[\hat{\theta} - \theta]^2$$

MSE (mean squared error)

On dit que $\hat{\theta}_1$ est meilleur que $\hat{\theta}_2$ ssi $R(\hat{\theta}_1, \theta) < R(\hat{\theta}_2, \theta)$



Exemple: [modèle de Poisson]

$X_1, \dots, X_n$ i.i.d de loi P_θ de Poisson, $\theta > 0$

Estimateur de θ ? $\theta = \mathbb{E}[X_i]$
 $\rightarrow \frac{1}{n} \sum_{i=1}^n X_i = \bar{X}$

$$B(\hat{\theta}, \theta) = \mathbb{E} \left[\frac{1}{n} \sum_{i=1}^n X_i \right] - \theta$$

linéarité

$$\downarrow = \frac{1}{n} \sum_i \mathbb{E}[X_i] - \theta$$

$$\begin{aligned} &\stackrel{\text{i.i.d}}{=} \frac{1}{n} \cdot n \mathbb{E}[X_1] - \theta \\ &= \mathbb{E}[X_1] - \theta = \theta - \theta = 0 \\ &\leadsto \mathbb{E}[\bar{X}] = \theta \end{aligned}$$

$$R(\hat{\theta}, \theta) = \mathbb{E}[(\bar{X} - \theta)^2] = \mathbb{E}[(\bar{X} - \mathbb{E}[\bar{X}])^2]$$

$$= \text{Var}(\bar{X})$$

$$= \text{Var}\left(\frac{1}{n} \sum_i X_i\right)$$

$$= \frac{1}{n^2} \text{Var}\left(\sum_i X_i\right)$$

$$\stackrel{\text{indép}}{=} \frac{1}{n^2} \sum_i \text{Var}(X_i) \stackrel{\text{i.i.d}}{=} \frac{1}{n} \cdot \text{Var}(X_1)$$

PROP: [décomposition biais-variance du risque]

$$R(\hat{\theta}, \theta) = (\text{Biais}(\hat{\theta}, \theta))^2 + \text{Var}(\hat{\theta})$$

$$\text{pv: } R(\hat{\theta}, \theta) = \mathbb{E}[(\hat{\theta} - \theta)^2]$$

$$\stackrel{\text{def}}{=} \mathbb{E}[(\hat{\theta} - \mathbb{E}[\hat{\theta}] + \mathbb{E}[\hat{\theta}] - \theta)^2]$$

$$= \mathbb{E}[(\hat{\theta} - \mathbb{E}[\hat{\theta}])^2] + \mathbb{E}[(\mathbb{E}[\hat{\theta}] - \theta)^2] + 2\mathbb{E}[(\hat{\theta} - \mathbb{E}[\hat{\theta}])(\mathbb{E}[\hat{\theta}] - \theta)]$$

$$= \text{Var}(\hat{\theta}) + (\text{B}(\hat{\theta}, \theta))^2 + 2\text{B}(\hat{\theta}, \theta)(\mathbb{E}[\hat{\theta}] - \mathbb{E}[\hat{\theta}])$$

4. Consistance

$\hookrightarrow$ propriété asymptotique

on ne considère que des constants.

DEF: $(X_1, \dots, X_n)$ i.i.d de loi P_θ , $\theta \in \Theta \subset \mathbb{R}^p$

Soit $\hat{\theta}_n = h(X_1, \dots, X_n)$. On considère la suite de v.a. $(\hat{\theta}_n)_{n \geq 1}$.

$\hat{\theta}_n$ est un estimateur consistant (ou convergent) de θ ssi : $\hat{\theta}_n \xrightarrow[n \rightarrow +\infty]{\mathbb{P}} \theta$

Rq: $(\hat{\theta}_n)$ est fortement consistant ssi : $\hat{\theta}_n \xrightarrow[n \rightarrow +\infty]{\text{p.s.}} \theta$

Exemple [modèle de poisson]

$$\theta = \mathbb{E}[X_i]; \hat{\theta}_n = \bar{X}$$

* On peut invoquer la LGN : $\bar{X} \xrightarrow[n \rightarrow +\infty]{\mathbb{P}} \theta = \mathbb{E}[X_i]$

$$\begin{aligned} * R(\hat{\theta}, \theta) &= \text{Var}(\bar{X}) = \frac{\theta}{n} \xrightarrow[n \rightarrow +\infty]{} 0 \\ &= \mathbb{E}[(\hat{\theta} - \theta)^2] \end{aligned}$$

$$\text{Ineq. BT: } \forall \varepsilon > 0, \mathbb{P}(|\hat{\theta} - \theta| > \varepsilon) \leq \frac{\mathbb{E}|\hat{\theta} - \theta|^2}{\varepsilon^2} = \frac{R(\hat{\theta}, \theta)}{\varepsilon^2} \xrightarrow{} 0$$

• $(X_1, \dots, X_n)$ i.i.d. Poisson(θ).

On veut estimer $\beta = \mathbb{P}(X_i = 0) = e^{-\theta}$

$\hookrightarrow \hat{\beta} = e^{-\hat{\theta}} = e^{-\bar{X}}$ [méthode "plug-in"]

$\hat{\beta}$ est consistant pour estimer β .

LEMME [de l'application continue]

Si $Z_n \xrightarrow{\mathbb{P}} Z$, alors $h(Z_n) \xrightarrow{\mathbb{P}} h(Z)$ $\forall h$ fonction continue